

### 3. Исследование нейронных сетей с радиально-базисными функциями (РБФ)

#### Цель работы:

- приобретение навыков построения, инициализации и обучения РБФ-НС
- исследование РБФ-НС при решении задач аппроксимации статических зависимостей и классификации

#### Теоретические сведения

##### РБФ-НС – общие сведения

НС с радиально-базисными функциями (РБФ) содержат в своем составе специальные РБФ-нейроны. Рассмотрим структуру РБФ-нейрона. Она отличается от структуры нейронов в обычных НС ПР.




Рис. Структура РБФ-нейрона

Во-первых, активация нейрона – это не сумма входных сигналов, взвешенных коэффициентами, а расстояние между вектором входных сигналов и вектором весовых коэффициентов

$$n = \|P - W\| * b$$

Во-вторых, передаточная функция нейрона является гауссианом:

$$a = \text{radbas}(n) = \exp(-n^2) = \exp\left(\frac{-\|P - W\|^2}{(1/b)^2}\right)$$




Рис. График радиально-базисной функции

Эта функция имеет максимум, равный 1, при  $n = 0$  и плавно убывает при увеличении  $n$ , достигая значения 0.5 при  $n = \pm 0.833$ . То есть, если входной вектор  $P$  полностью совпадает с вектором весовых коэффициентов, то на выходе РБФ-нейрона будет 1. Если же расстояние между  $P$  и  $W$ , равняется  $0.833/b$ , то на выходе нейрона будет 0.5. С дальнейшим увеличением расстояния между  $P$  и  $W$  выходное значение  $a$  стремится к 0. В связи с этим вектор весовых коэффициентов часто называется **центром** РБФ-нейрона.

Из выражения для  $a$  видно, что  $b$  влияет на скорость убывания функции выхода  $a$  от расстояния  $\|P - W\|$ . С ростом  $b$  функция убывает быстрее, с уменьшением  $b$  она убывает медленнее.

### Базовая РБФ-НС

Базовая РБФ-НС состоит из двух слоев. Первый слой представлен РБФ-нейронами, второй слой – линейный.




Рис. Структура базовой РБФ-НС

РБФ-нейроны первого слоя играют роль детекторов значений входного сигнала. Нейроны второго, линейного слоя проецируют на выход сигналы от РБФ-нейронов.

### Синтез РБФ-НС для решения задачи аппроксимации

За счет своей организации РБФ-НС могут быть легко использованы для решения задачи аппроксимации непрерывных функций. Для этого необходимо в РБФ-слой записать наиболее характерные значения входного аргумента, а линейный слой настроить так, чтобы суммарная ошибка была минимальной.

В случае если имеется обучающая выборка, возможны два варианта:

1. Точный синтез РБФ-НС. Для каждого примера  $(P_i, T_i)$  создается РБФ-нейрон с центром, соответствующим входному вектору примера  $P_i$ . Затем для каждого примера  $P_i$  вычисляется отклик всех РБФ-нейронов  $A^{(i)} = [A_1^{(i)} A_2^{(i)} \dots A_{S^1}^{(i)}]$ . Для вычисления коэффициентов линейного слоя решается система уравнений

$$[A^{(1)}; A^{(2)}; \dots; A^{(n)}]W = [T^{(1)}; T^{(2)}; \dots; T^{(S^2)}].$$

2. Приближенный синтез РБФ-НС. Задается максимально допустимая ошибка аппроксимации. РБФ-нейрон создается не для каждого примера, а лишь для части. В результате система уравнений для нахождения коэффициентов линейного слоя получается неполной и появляется ненулевая ошибка. Если эта ошибка меньше допустимой, то РБФ-НС считается сформированной. В противном случае увеличивается число РБФ-нейронов.

В случае приближенного синтеза достаточно "остро" встает проблема выбора набора примеров, составляющих центры РБФ-нейронов. В простейшем случае можно выбрать примеры как-то случайно. Более сложные алгоритмы предполагают предварительную **кластеризацию** множества входных данных с заданием в качестве числа кластеров числа РБФ-нейронов. В результате кластеризации формируются центры РБФ-нейронов.

### Выбор параметра $b$ – ширины гауссиана

В обоих случаях помимо обучающей выборки необходимо задать параметр  $b$ , определяющий скорость убывания функции РБФ-нейронов от расстояния. Очевидно, что он зависит от типа аппроксимируемой функции. В точках, где функция изменяется быстро,  $b$  нужно задавать больше, где медленно – меньше. Если параметр  $b$  задан неверно, то аппроксимация будет неудовлетворительной

- если функция медленно изменяющаяся, а РБФ-нейроны быстрые, то в точках, соответствующих обучающим примерам, аппроксимация будет хорошей, а в точках между обучающими примерами аппроксимация будет очень плохой;

- если функция быстро изменяющаяся, а РБФ-нейроны медленные, то, скорее всего, система уравнений для нахождения  $W$  будет иметь неполный ранг и аппроксимация будет плохой во всех точках.

Таким образом, для настройки РБФ-НС необходимо правильно подобрать следующие параметры:

- количество РБФ-нейронов
- примеры, входные значения которых будут являться центрами РБФ-нейронов
- скорость РБФ-нейронов (скорость убывания функции выхода от расстояния).

При этом критерием выбора этих параметров является ошибка аппроксимации на тестовой выборке.

В отличие от НСПР с сигмоидальными нейронами РБФ-НС требуют для аппроксимации большего числа нейронов, но при этом их обучение занимает гораздо меньшее время. Это объясняется тем, что сигмоидальные функции изменяются в большем диапазоне входных значений, чем радиально-базисные функции.

### РБФ-НС с обобщенной регрессией (GRNN)

Помимо стандартных РБФ-НС были предложены т.н. РБФ-НС с обобщенной регрессией (Generalized Regression NN, GRNN), отличающиеся выходным слоем. Этот слой для вычисления активации использует не просто скалярное произведение -  $V=W*P$ , а скалярное произведение с нормализацией  $V=W*P/\text{sum}(P)$ . GRNN предназначены для аппроксимации функций.




Рис. Структура GRNN

Весовые коэффициенты от  $i$  РБФ-нейрона к выходному слою задаются равными  $T_i$  - выходным сигналам  $i$  примера. В результате, при подаче на вход НС сигнала  $P$ , близкого к  $P_i$  - входному сигнала  $i$  примера, соответствующий  $i$  РБФ-нейрон выдаст значение, близкое к 1, а остальные РБФ-нейроны в идеале выдадут значения, близкие к нулю. В соответствии с весовыми коэффициентами на выходе РБФ-НС будет значение, близкое к  $T_i$ . Если же входной сигнал  $P$  находится примерно посередине между  $P_i$  и  $P_j$  -  $P = (P_i + P_j)/2$ , то на выходе НС будет значение, близкое к  $(T_i + T_j)/2$  (при условии правильного задания ширины гауссианов).

### Вероятностные НС (PNN)

Классические РБФ-НС используются для аппроксимации непрерывных функций. Это происходит из-за того, что выходной слой в них линейный. Если же сделать этот слой соревновательным, то РБФ-НС смогут решать задачу классификации. Соответствующие НС называются еще вероятностными НС (Probability Neural Network). Название происходит от того, что соревновательная передаточная функция применяется к набору значений, физический смысл которых - вероятность того, что входной сигнал принадлежит соответствующему классу. В результате выбирается тот класс, к которому входной образ подходит с максимальной вероятностью.

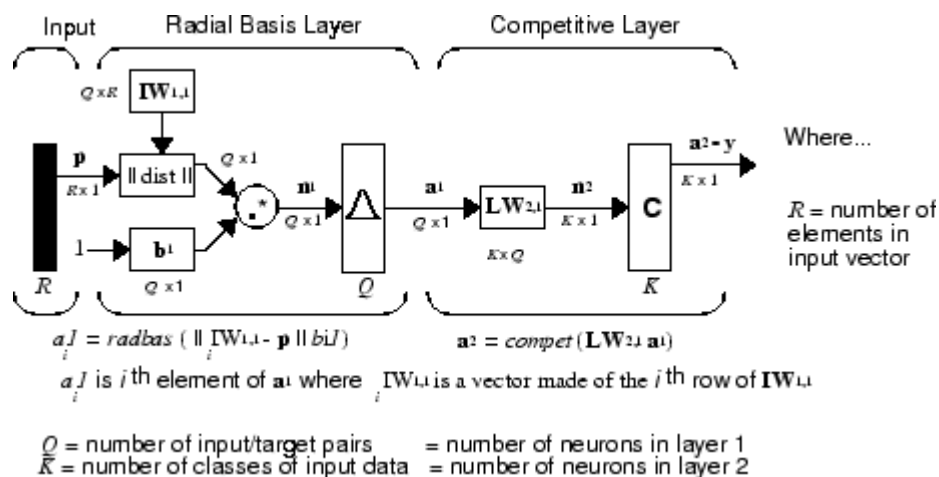


Рис. Структура PNN

РБФ-нейроны в PNN настраиваются также, как и во всех РБФ-НС – центры РБФ-нейронов соответствуют векторам входных значений примеров.

Весовые коэффициенты от  $i$  РБФ-нейрона к нейронам соревновательного слоя по аналогии с GRNN задаются равными  $T_i$  - желаемым выходным сигналам  $i$ -го примера. В данном случае  $T_i$  содержит информацию о том, к какому классу принадлежит  $i$ -й пример (если  $i$ -й пример относится к  $j$  классу, то  $T_i(j)=1$ ,  $T_i(k)=0$ ,  $k \neq j$ ).

Недостаток PNN – если на входе будет образ, не похожий ни на один из классов, то на выходе все равно будет один из классов.

### Построение РБФ-НС в среде Matlab

#### Формирование на уровне нейронов

Рассмотрим вначале, формирование РБФ-НС на уровне нейронов, а затем перейдем к формированию на уровне НС.

РБФ-нейрон отличается от обычных нейронов алгоритмом вычисления активации и передаточной функцией. Поэтому в Matlab для нейронов РБФ-слоя необходимо задать следующие параметры (предполагается, что РБФ-нейроны располагаются в первом слое):

- вычисление расстояния между входным вектором и вектором весовых коэффициентов: `net.inputWeights{1,1}.weightFcn = 'dist'`;
- умножение расстояния на смещение: `net.layers{1}.netInputFcn = 'netprod'`;
- применение РБФ: `net.layers{1}.transferFcn = 'radbas'`.

Обобщая, можно записать, что выход  $a\{i\}$   $i$ -го РБФ-нейрона в Matlab вычисляется по формуле

$$a\{i\} = \text{radbas}(\text{netprod}(\text{dist}(\text{net.IW}\{1,1\}(i,:), p), \text{net.b}\{1\}))$$

Выходной слой стандартной РБФ-НС является линейным, поэтому нейроны этого слоя имеют следующие параметры, определяющие алгоритм их работы:

- `net.layerWeights{2,1}.weightFcn = 'dotprod'`;
- `net.layers{2}.netInputFcn = 'netsum'`;
- `net.layers{2}.transferFcn = 'purelin'`.

В РБФ-НС с обобщенной регрессией (GRNN) выходной слой является модифицированным линейным (активация вычисляется, как скалярное произведение с нормализацией) поэтому нейроны от нейронов линейного слоя отличаются в следующем:

- `net.layerWeights{2,1}.weightFcn = 'normprod'`

Наконец, в PNN выходной слой является соревновательным, поэтому нейроны от нейронов линейного слоя отличаются в следующем:

- `net.layers{2}.transferFcn = 'compet'`

### Формирование на уровне НС (задачи)

В Matlab имеются несколько встроенных функций, которые значительно упрощают процедуру создания и формирования РБФ-НС: newrb, newrbe, newgrnn, newpnn. Рассмотрим каждую из этих функций отдельно.

#### Функция newrbe - создание точной РБФ-НС (по всему набору примеров)

```
net = newrbe(P,T,spread)
```

P – набор желаемых входных значений примеров (матрица  $R \times Q$ )

T – набор желаемых выходных значений примеров (матрица  $S \times Q$ )

spread – параметр, управляющий шириной гауссианов РБФ-нейронов

Смещение всех элементов в слое выбирается равным  $b = 0.8326/\text{spread}$ . С увеличением значения spread гауссоида расширяется, с уменьшением – сужается. Если расстояние между входным вектором и центром РБФ-нейрона равно 0, то на выходе нейрона будет 1, если расстояние равно spread, то на выходе РБФ-нейрона будет 0.5. То есть spread определяет ширину гауссиан слоя РБФ-нейронов.

#### Функция newrb - создание приближенной РБФ-НС (с заданной ошибкой)

```
net = newrb(P,T,goal,spread,MN,DF)
```

Параметры P, T, spread имеют тот же смысл, что и newrbe

goal – максимально допустимая ошибка

MN – максимальное количество нейронов (по умолчанию Q – число примеров)

DF – через какое количество добавляемых нейронов производить визуализацию

#### Функция newgrnn - создание GRNN (по алгоритму) для аппроксимации

```
net = newgrnn(P,T,spread)
```

Параметры P, T, spread имеют тот же смысл, что и в функции newrbe.

#### Функция newpnn - создание PNN (по алгоритму) для классификации

```
net = newpnn(P,T,spread)
```

Параметры P, T, spread имеют тот же смысл, что и в функции newrbe.

## Примеры

### Пример 1 – РБФ –нейронные сети для аппроксимации

1. Постройте график радиально-базисной функции

```
x = -3:1:3;  
a = radbas(x);  
plot(x,a)  
title('Radial Basis Transfer Function');  
xlabel('Input p');  
ylabel('Output a');
```

2. Постройте композицию трех РБФ в разных точках и с различными весами

```
a2 = radbas(x-1.5);  
a3 = radbas(x+2);  
a4 = a + a2*1 + a3*0.5;  
plot(x,a,'b-',x,a2,'b--',x,a3,'b--',x,a4,'m-')  
title('Weighted Sum of Radial Basis Transfer Functions');  
xlabel('Input p');  
ylabel('Output a');
```

3. Сформируйте аппроксимируемую зависимость в виде набора точек и постройте ее.

```
X = -1:1:1;  
T = [-.9602 -.5770 -.0729 .3771 .6405 .6600 .4609 ...  
.1336 -.2013 -.4344 -.5000 -.3930 -.1647 .0988 ...  
.3072 .3960 .3449 .1816 -.0312 -.2189 -.3201];  
plot(X,T,'+');  
title('Training Vectors');  
xlabel('Input Vector P');  
ylabel('Target Vector T');
```

4. Для сформированной зависимости создайте и обучите РБФ-НС с допустимой ошибкой 0.02 и шириной РБФ, равной 1.

```
eg = 0.02; % sum-squared error goal  
sc = 1; % spread constant  
net = newrb(X,T,eg,sc);
```

5. Постройте график функции, реализуемой РБФ-НС

```
plot(X,T,'+');  
xlabel('Input');  
  
X = -1:0.01:1;  
Y = net(X);  
  
hold on;  
plot(X,Y);  
hold off;  
legend({'Target','Output'})
```

6. Задайте ширину РБФ spread равной 0.01, создайте РБФ-НС, обучите ее и постройте график функции, реализуемой РБФ-НС. Сравните результаты.

7. Задайте ширину РБФ spread равной 100, создайте РБФ-НС, обучите ее и постройте график функции, реализуемой РБФ-НС. Сравните результаты.

### Пример 2 – Нейронная сеть обобщенной регрессии (GRNN)

1. Сформируйте аппроксимируемую зависимость и постройте ее.

```
X = [1 2 3 4 5 6 7 8];  
T = [0 1 2 3 2 1 2 1];  
  
plot(X,T,'.','markersize',30)  
axis([0 9 -1 4])  
title('Function to approximate.')  
xlabel('X')
```

```
ylabel('T')
```

2. Сформируйте GRNN с шириной РБФ, равной 0.7, обучите ее на исходную зависимость и постройте результаты аппроксимации РБФ-НС в точках обучающей выборки.

```
spread = 0.7;  
net = newgrnn(X,T,spread);  
A = net(X);  
hold on  
outputline = plot(X,A,'.','markersize',30,'color',[1 0 0]);  
title('Create and test y network.')  
xlabel('X')  
ylabel('T and A')
```

3. Постройте результат аппроксимации в точке  $x=3.5$

```
x = 3.5;  
y = net(x);  
plot(x,y,'.','markersize',30,'color',[1 0 0]);  
title('New input value.')  
xlabel('X and x')  
ylabel('T and y')
```

4. Постройте плавный график кривой, реализуемой GRNN

```
X2 = 0:1:9;  
Y2 = net(X2);  
plot(X2,Y2,'linewidth',4,'color',[1 0 0])  
title('Function to approximate.')  
xlabel('X and X2')  
ylabel('T and Y2')
```

### Пример 3 – Вероятностная нейронная сеть (PNN)

1. Сформируйте три 2-мерные точки, каждая из которых принадлежит отдельному классу и постройте их на графике.

```
X = [1 2; 2 2; 1 1];  
Tc = [1 2 3];  
plot(X(1,:),X(2,:),',' markersize',30)  
for i=1:3, text(X(1,i)+0.1,X(2,i),sprintf('class %g',Tc(i))), end  
axis([0 3 0 3])  
title('Three vectors and their classes.')  
xlabel('X(1,:)')  
ylabel('X(2,:)')
```

2. Создайте PNN для классификации трех точек

```
T = ind2vec(Tc);  
spread = 1;  
net = newpnn(X,T,spread);
```

3. Постройте на графике результаты классификации (точка и класс)

```
Y = net(X);  
Yc = vec2ind(Y);  
plot(X(1,:),X(2,:),',' markersize',30)  
axis([0 3 0 3])  
for i=1:3, text(X(1,i)+0.1,X(2,i),sprintf('class %g',Yc(i))), end  
title('Testing the network.')  
xlabel('X(1,:)')  
ylabel('X(2,:)')
```

4. Произведите классификацию новой точки  $x = [2; 1.5]$

```
x = [2; 1.5];  
y = net(x);  
ac = vec2ind(y);  
hold on  
plot(x(1),x(2),'.','markersize',30,'color',[1 0 0])  
text(x(1)+0.1,x(2),sprintf('class %g',ac))  
hold off
```

```
title('Classifying y new vector.')
xlabel('X(1,:) and x(1)')
ylabel('X(2,:) and x(2)')
```

5. Постройте диаграмму Вороного, демонстрирующую разбиение плоскости на классы, реализуемое PNN

```
x1 = 0:0.05:3;
x2 = x1;
[X1,X2] = meshgrid(x1,x2);
xx = [X1(:) X2(:)];
yy = net(xx);
yy = full(yy);
m = mesh(X1,X2,reshape(yy(1,:),length(x1),length(x2)));
set(m,'facecolor',[0 0.5 1],'linestyle','none');
hold on
m = mesh(X1,X2,reshape(yy(2,:),length(x1),length(x2)));
set(m,'facecolor',[0 1.0 0.5],'linestyle','none');
m = mesh(X1,X2,reshape(yy(3,:),length(x1),length(x2)));
set(m,'facecolor',[0.5 0 1],'linestyle','none');
plot3(X(1,:),X(2,:),[1 1 1]+0.1,',' , 'markersize',30)
plot3(x(1),x(2),1.1,',' , 'markersize',30,'color',[1 0 0])
hold off
view(2)
title('The three classes.')
xlabel('X(1,:) and x(1)')
ylabel('X(2,:) and x(2)')
```



## **Практические задания**

### **Задание 1 – Аппроксимация с помощью базовой РБФ-НС и GRNN**

**1. С помощью точной РБФ-НС (*newrb*) аппроксимируйте функцию (для вашего варианта из заданий с номером 5).**

а. *Задайте* достаточное для точной аппроксимации количество обучающих примеров (в данном случае совпадающее с числом РБФ-нейронов).

б. Изменяя ширину РБФ (*spread*), *определите наилучшее значение* этого параметра с точки зрения качества аппроксимации. *Постройте три графика аппроксимации* для разных значений *spread*: оптимального, больше и меньше оптимального, когда явно видно, что аппроксимация плохая. При построении графиков аппроксимации не забывайте приводить графики исходной желаемой зависимости.

в. *Постройте график* зависимости ошибки аппроксимации от параметра *spread* в логарифмическом масштабе.

### **2. Произведите аппроксимацию с помощью, приближенной РБФ-НС (*newrb*).**

а. *Используйте* найденное в п.1 оптимальное значение *spread* и достаточный для точной аппроксимации объем обучающей выборки.

б. Изменяя значение допустимой ошибки (*goal*), *постройте зависимость* числа используемых РБФ-нейронов от допустимой ошибки аппроксимации. Для промежуточных результатов *постройте графики аппроксимации*.

Зам. Для более точного нахождения количества нейронов, при которых достигается заданная цель (значение ошибки), количество нейронов, прибавляемое на каждом шаге (5-й параметр *newrb*, *DF*), следует задавать не очень большим.

Зам. Максимальное количество нейронов (4-й параметр функции *newrb*, *MN*) по построению РБФ-НС не может превышать объема обучающей выборки.

### **3. Выполните аппроксимацию с помощью GRNN.**

а. *Задайте* вначале достаточный для точной аппроксимации объем обучающей выборки.

б. По аналогии с *newrb* изменяя ширину РБФ (*spread*), *определите наилучшее значение* этого параметра с точки зрения качества аппроксимации. *Постройте график* аппроксимации на исходной зависимости.

в. Уменьшите объем обучающей выборки в несколько раз (рассмотрите 3 случая) и *подберите оптимальные значения* параметра *spread* для каждого случая. *Постройте полученные графики* аппроксимации. Приведите значения ошибок.

**3. Сравните качество аппроксимации сетями прямого распространения и различными вариантами РБФ-НС (точной, приближенной РБФ-НС и GRNN) по различным показателям:**

- число нейронов, требуемое для достижения заданного качества аппроксимации;
- время обучения;
- сложность настройки (выбора параметров) НС.

*Постройте на одном графике* зависимости ошибки от числа нейронов для различных типов НС.

Зам. При расчете ошибок для различных типов НС следует использовать одни и те же формулы.

### **Задание 2 – Классификация с помощью PNN (2 класса)**

1. *Задайте* достаточное для точной классификации количество обучающих примеров.

2. *Подберите оптимальное значение* *spread* в смысле минимальной ошибки на тестовой выборке. *Визуализируйте* результаты классификации (диаграмма соотнесения тестовых примеров с классами, раскраска плоскости). *Приведите значение* средней ошибки.

3. Постройте дополнительно графики классификации для значений spread, больших и меньших оптимального, когда явно видно, что классификация неудовлетворительная.

4. Уменьшите объем обучающей выборки в несколько раз (рассмотрите 3 случая) и подберите оптимальные значения параметра spread для каждого случая. Визуализируйте результаты классификации и приведите значение средней ошибки.

5. Постройте поверхность ошибки в плоскости двух параметров: ширина РБФ-функции spread и объем обучающей выборки.

6. Сравните полученные результаты с НС прямого распространения по аналогии с п. 3 задания 1.

### **Задание 3 – Классификация с помощью PNN (>2 классов)**

С помощью PNN произведите классификацию линейно неразделимых образов (для вашего варианта из заданий с номером 4) по аналогии с заданием 2.

Для п. 2 и 3 дополнительно приведите матрицы неточностей и рассчитайте ошибки первого и второго родов.

### **Задание 4 – Классификация многомерных образов с помощью PNN**

Попробуйте решить задачу классификации многомерных образов с помощью PNN.

1. Сформируйте обучающую выборку достаточного объема.

2. Подберите оптимальное значение spread.

3. Исследуйте качество классификации на тестовой выборке, содержащей зашумленные примеры. Приведите матрицу неточностей, рассчитайте среднюю ошибку и ошибки 1,2 родов.

4. Попробуйте увеличить и уменьшить объем обучающей выборки в несколько раз. Для каждого случая подберите оптимальное значение spread и рассчитайте показатели качества классификации.

5. Проанализируйте полученные результаты, сравнив их с результатами классификации тех же самых образов НС прямого распространения по аналогии с п. 3 задания 1.